

Klasyfikator zdjęć zwierząt z wykorzystaniem konwolucyjnych sieci neuronowych

Tomasz Szewczuk, 226163

Wydział Elektroniki
Politechnika Wrocławska
Wrocław, Polska
226163@student.pwr.edu.pl

Adam Węglowski, 226175

Wydział Elektroniki
Politechnika Wrocławska
Wrocław, Polska
226175@student.pwr.edu.pl

Streszczenie - W pracy przedstawione zostało działanie konwolucyjnych sieci neuronowych dla podstawie poprawności rozpoznawania obiektów, w tym przypadku wykorzystana została baza danych składająca się ze zdjęć psów oraz kotów. Dodatkowo wykorzystany został transfer learning, który pokazał możliwość ponownego wykorzystania wcześniej przygotowanej sieci neuronowej do rozwiązywania innego problemu badawczego. Eksperyment został przeprowadzony zgodnie z planem, a jego wyniki zostały przedstawione i omówione.

Słowa kluczowe: sieci neuronowe, sztuczna inteligencja, sieć konwolucyjna, sieci głębokie, przetwarzanie obrazu

1. INFORMACJE OGÓLNE

W ostatnich latach nastąpił dynamiczny rozwój sztucznej inteligencji, a wraz z nią głębokich i konwolucyjnych sieci neuronowych. Algorytmy uzyskują bardzo wysokie wyniki w wielu zadaniach między innymi w rozpoznawaniu obrazu, rozpoznawaniu mowy lub tekstu pisanego. Podczas badań zostało przeanalizowane działanie głębokich sieci neuronowych do analizy obrazu. Zaletą głębokich sieci neuronowych jest możliwość wydobywania istotnych cech obrazu.

W przeprowadzonych badaniach zostało przeanalizowane działanie modeli głębokich sieci neuronowych. Głównym celem badań było wykazanie wzrostu precyzji głębokich konwolucyjnych sieci neuronowych przy zastosowaniu transfer learningu w zadaniach rozpoznawania obiektów na obrazach graficznych. Dodatkowym celem pracy było przybliżenie czytelnikom głębokich i konwolucyjnych sieci neuronowych na przykładzie klasyfikacji zdjęć.

2. OPIS TECHNOLOGII

2.1 Sieci neuronowe

Sieci neuronowe zyskały swoją popularność już w poprzednich dekadach ubiegłego wieku, jednak ich prawdziwy rozwój miał miejsce dopiero w XXI wieku. Są one jednym z wielu zagadnień, szeroko pojętej, sztucznej inteligencji. Zyskują one coraz większe zainteresowanie wśród naukowców i obserwatorów interesujących się nowymi technologiami. [2]

Podstawowym elementem budowy sieci neuronowych jest pojedynczy neuron, który łączy się z innymi neuronami, tworząc poszczególne warstwy sieci. Budowa oraz sposób działania ma naśladować działanie ludzkiego mózgu.

Sieć neuronowa składa się najczęściej z trzech połączonych ze sobą warstw. Pierwsza warstwa nazywana jest warstwą wejścia – gromadzi ona dane, a następnie przesyła dalej (każdy neuron pierwszej warstwy dostarcza dane, do każdego neuronu drugiej warstwy, czyli warstwy ukrytej). Druga warstwa to już wspomniana wyżej warstwa ukryta – to w niej ma miejsce proces uczenia. Trzecia warstwa to warstwa wyjściowa – dostarcza wyniki przeprowadzonego eksperymentu.

Na pierwszy rzut oka układ wydaje się prosty, jednak nie ujmując to złożoności, ponieważ sieć może opierać się na nieskończonej liczbie warstw neuronowych.

2.2 Sieci konwolucyjne

Ideą sieci konwolucyjnych jest analiza obrazu poprzez wyuczenie parametrów filtra (połączenie neuronów z tego samego obszaru z neuronem z warstwy wyższej) bądź zestawu filtrów, które najlepiej wydobydą informacje z danych wejściowych w ramach zadanego problemu. Filtrów wykrywających pewne niskopoziomowe cechy obrazka może być dużo, wszystkie one tworzą tzw. warstwę konwolucyjną. Warstwa konwolucyjna (nazywana również mapą cech) to szczególny rodzaj sieci neuronowej, która pozwala manipulować obrazem w celu wyróżnienia jego niektórych cech. Taka warstwa składa się z jednostek analizujących niewielki obszar danych wejściowych, np. 5x5 pikseli. W wyniku takich działań sieci CNN wzorce są niezależne od przesunięcia.

Mapy cech są trójwymiarowym tensorem zawierających dwie przestrzenne osie definiujące wysokość i szerokość. Trzecią osią jest oś głębi. W przypadku obrazu RGB oś głębi ma trzy wymiary. Obrazy monochromatyczne, mają jeden wymiar głębi opisujący skalę nasycenia szarości. W praktyce warstwa odpowiada jednej cesze, która rzadko wystarcza dla modelowanego problemu, dlatego w jednej sieci występuje wiele warstw konwolucyjnych. Warstwa konwolucyjna wprowadza redundancje danych. Sąsiednie jednostki częściowo pokrywają te same obszary danych wejściowych. Może dojść do sytuacji, że informacja o wystąpieniu cechy w danym obszarze została wydobyta przez różne jednostki. Może to spowodować większą złożoność analityczną. W celu poradzenia sobie z tym zjawiskiem został wprowadzony pooling layer. Pooling layer ma za zadanie wydobyć najważniejsze cechy z wcześniejszych warstw powodując rozwiązanie problemu nadmiarowości. [3][4][7]

2.3 Transfer learning

Podczas pracy wykorzystany został transfer learning, czyli uczenie transferowe. Metoda służy do ponownego wykorzystania wcześniej przygotowanej sieci neuronowej do rozwiązywania innego problemu. Ogólną ideą jest wykorzystanie wiedzy, której model nauczył się z zadania, w którym dostępne jest wiele etykietowanych danych szkoleniowych, do nowego zadania. Zamiast zaczynać proces uczenia od zera, zostanie rozpoczęty od wzorców, których sieć nauczyła się przy rozwiązywaniu poprzedniego, podobnego zadania.

Technika transfer learning jest mocno użyteczna w problemach, w których dostarczona ilość danych jest zbyt mała do przeprowadzenia efektywnego procesu uczenia. Dotyczy również problemu doboru optymalnych parametrów sieci neuronowej.

Zaletą tej metody jest bez wątpienia możliwość budowy wnikliwego modelu uczenia maszynowego z relatywnie małymi danymi treningowymi, ponieważ model jest już wstępnie przygotowany. [1][5]

3. BAZA DANYCH

Do analizy działania konwolucyjnych sieci neuronowych została wykorzystana baza danych, która zawiera zdjęcia psów oraz kotów. Zbiór danych dostępny jest na portalu Kaggle [6]. Baza danych wykorzystywana jest do testowania działania systemów klasyfikujących obraz. Ponadto zbiór zdjęć umożliwia łatwą analizę działania głębokich sieci neuronowych ze względu na łatwość interpretacji zdjęć zwierząt przez człowieka. Baza danych posiada 25 tys. zdjęć zwierząt różnej rozdzielczości, równo podzielonych na dwie klasy. Wybrana baza danych jest odpowiednim zbiorem do uczenia konwolucyjnych sieci neuronowych ze względu na następujące cechy: równa liczba zdjęć w obu klasach, bardzo zróżnicowane zdjęcia o różnych rozmiarach, zdjęcia wykonane w różnych warunkach oświetleniowych oraz otoczeniu. Baza danych zajmuje 812 MB. Rozmiar obrazów jest bardzo zróżnicowany od 60x40 do 1024x768. Zbiór danych został podzielony na trzy podzbiory: train, valid, test. W zbiorze treningowym znajdują się 2000 próbek (1000 zdjęć psów i 1000 zdjęć kotów), do zbioru walidacyjnego trafiło 1000 próbek (500 zdjęć psów i 500 zdjęć kotów), zaś do zbioru testowego ostatnie 1000 próbek (500 zdjęć psów i 500 zdjęć kotów).

4. PROCES UCZENIA

W celu dopasowania rozmiaru obrazów do rozmiaru wejścia sieci neuronowych wszystkie obrazy ze zbioru treningowego i walidacyjnego zostały przeskalowane do rozmiaru 150x150 pikseli. Następnie przeskalowane zostały wartości pikseli, tak aby zawierały się w przedziale od 0 do 1.

W celu zwiększenia możliwości generalizacji sieci neuronowej wykorzystane zostało rozszerzenie danych zbioru treningowego. Rozszerzanie danych polega na dodaniu niewielkich modyfikacji do zdjęcia, które nie powodują zmiany klasy obiektu znajdującego się na zdjęciu, natomiast znacznie zmienia się reprezentacja obrazu zapisanego w pamięci komputera w postaci macierzy. W

pracy zastosowane zostały następujące modyfikacje: odbicie w pionie oraz w poziomie, obroty, rozciąganie i zwężanie oraz przesunięcia. Losowa modyfikacja stosowana była przed każdym podaniem zdjęcia na sieć.

W trakcie badań został użyty również transfer learning oraz technika dostrajania.

5. SPRZĘT I OPROGRAMOWANIE

Uczenie głębokich sieci neuronowych wymaga silnych jednostek obliczeniowych. Obliczenia prowadzone były z wykorzystaniem kart graficznych NVIDIA, ponieważ wspierają uczenie głębokie sieci neuronowych. Do przeprowadzenia badań zostało wykorzystane środowisko Google Colab wraz z językiem programowania Python.

6. STUDIA LITERATUROWE

W artykule *Convolutional Neural Networks for Document Image Classification* autorstwa Le Kang, Jayant Kumar, Peng Ye, Yi Li, David Doermann przedstawiono konwolucyjną sieć neuronową do klasyfikacji obrazów dokumentów. Sieć CNN zastosowana w badaniach działała dobrze, nawet gdy układy dokumentów prezentowały bardzo duże różnice wewnątrz klasy (dotyczyły tego samego problemu). Eksperymenty na publicznych zestawach danych pokazują skuteczność proponowanego przez autorów podejścia.

Alexander Gomez, German Diez, Augusto Salazar, Angelica Diaz w pracy zatytułowanej *Animal Identification in Low Quality Camera-Trap Images Using Very Deep Convolutional Neural Networks and Confidence Thresholds* z 2016 roku badają zastosowanie głębokich konwolucyjnych sieci neuronowych w rozpoznawaniu obiektów na obrazach niskiej jakości. Ich badania mają znaleźć zastosowanie przy rozpoznawaniu zwierząt w środowisku naturalnym bez zakłócania ich życia. Zaproponowane metody przy rozpoznawaniu obrazów charakteryzowały się bardzo wysoką skutecznością (97%). W swojej pracy proponują tryb łagodzenia, wykorzystujący próg ufności automatycznej klasyfikacji, pozwalający systemowi osiągnąć wydajność porównywalną z ludzką.

W książce, *Deep Learning Praca z językiem Python i biblioteką Keras*, której autorem jest Francois Chollet opisywane są szczegółowo: sposób działania głębokiej sieci neuronowej, jej zastosowania oraz metody tworzenia takiej sieci wraz z użyciem biblioteki Keras.

Publikacja *ImageNet Classification with Deep Convolutional Neural Networks* dotyczy uczenia dużej konwolucyjnej sieci neuronowej. Zadaniem była klasyfikacja 1,3 miliona obrazów o dużej rozdzielczości do 1000 różnych klas. W badaniach osiągnięto najwyższy poziom błędu na poziomie około 40%, natomiast najniższy poziom to 18,9%. Zaprojektowana sieć neuronowa, ma 60 milionów parametrów i 500 000 neuronów, składa się z pięciu warstw konwolucyjnych. Aby przyspieszyć proces uczenia, zastosowano nienasycone neurony i bardzo wydajną implementację sieci konwolucyjnych przez GPU. Wyniki opublikowane w artykule pokazują, że duża, głęboko splotowa sieć neuronowa jest w stanie osiągnąć

bardzo dobre wyniki na bardzo trudnym zestawie danych z wykorzystaniem wyłącznie nadzorowanego uczenia się.

W artykule *Deep learning* autorstwa Yann'a LeCun'a, Yoshua Bengio oraz Geoffrey'a Hinton'a poruszony został temat głębokiego uczenia. Głębokie uczenie pozwala modelom obliczeniowym wielowarstwowym na naukę reprezentacji danych o wielu poziomach abstrakcji. Metody te bardzo poprawiły systemy rozpoznawania mowy, rozpoznawania obiektów, wykrywania obiektów oraz wiele innych. Głębokie uczenie, za pomocą propagacji wstecznej, ujawnia skomplikowane struktury w dużych ilościach danych. Wskazuje, jak sieć powinna zmieniać swoje parametry, które są używane do obliczenia wartości w każdej warstwie z wartości w warstwie poprzedniej.

W publikacji Ling Shao, Fan Zhu, Xuelong Li pod tytułem *Transfer Learning for Visual Categorization: A Survey* z 2014 roku zostały zbadane najnowocześniejsze algorytmy uczenia sieci neuronowych w aplikacjach klasyfikacji wizualnej, takich jak rozpoznawanie obiektów, klasyfikacja obrazów i rozpoznawanie ludzkich działań. Z wyników badań wynika, iż transfer learning poprawia działanie sieci, jednakże wciąż nie jest ona doskonała, ponieważ opiera się tylko na danych na małą skalę, które nie mogą dobrze odzwierciedlić potencjalnej przewagi transfer learningu nad zwykłym uczeniem.

7. ZAŁOŻENIA PROJEKTOWE

- Wykazanie wzrostu precyzji głębokich konwolucyjnych sieci neuronowych przy zastosowaniu transfer learningu w zadaniach rozpoznawania obiektów na obrazach graficznych.
- Wykazanie, że transfer learning pozwala trenować modele w znacznie krótszym czasie przy zdecydowanie większej skuteczności wobec modelu opartego tylko na nieprzetrenowanych danych.
- Stworzenie modelu konwolucyjnej sieci neuronowej do klasyfikacji obrazów graficznych.
- Zastosowanie techniki dostrajania konwolucyjnej sieci neuronowej.
- Zastosowanie *transfer learning* do klasyfikacji graficznych obrazów.
- Przeprowadzenie analizy porównawczej stworzonych modeli.

8. PLAN EKSPERYMENTU

1. Wybór technologii

W celu przeprowadzenia badań zostało wybrane odpowiednie środowisko oraz język programowania.

2. Dobór bazy danych, na której zostaną przeprowadzone badania

Baza danych wykorzystana do badań zawiera zdjęcia psów oraz kotów. Zbiór danych dostępny jest na portalu Kaggle. Baza danych posiada 25 tys. zdjęć zwierząt różnej rozdzielczości, równo

podzielonych na dwie klasy. Wybrana baza danych jest odpowiednim zbiorem do uczenia konwolucyjnych sieci neuronowych ze względu na następujące cechy: równa liczba zdjęć w obu klasach, bardzo zróżnicowane zdjęcia o różnych rozmiarach, zdjęcia wykonane w różnych warunkach oświetleniowych oraz otoczeniu. Rozmiar obrazów jest bardzo zróżnicowany od 60x40 do 1024x768.

3. Wybór metryki do przeprowadzenia badań wydajnościowych

Jakość wytrenowanych modeli została sklasyfikowana poprzez określenie ich dokładności trenowania i walidacji oraz straty trenowania i walidacji.

4. Wybór miar statystycznych do analizy danych

W celu oceny algorytmów klasyfikacji wykorzystane zostały następujące miary statystyczne: dokładność, czułość, swoistość. Dokładność jest stosunkiem liczby poprawnie sklasyfikowanych obrazów do liczby wszystkich obrazów w bazie. Czułość jest stosunkiem poprawnie sklasyfikowanych przykładów pozytywnych (w tym przypadku psy) do całkowitej ilości przykładów pozytywnych w zbiorze. Natomiast swoistość jest stosunkiem poprawnie sklasyfikowanych przykładów negatywnych (w tym przypadku koty) do całkowitej ilości przykładów negatywnych w zbiorze.

5. Dostosowanie danych do eksperymentu

Zbiór danych został podzielony na trzy podzbiory: train, valid, test. W zbiorze treningowym znalazło się 2000 próbek (1000 zdjęć psów i 1000 zdjęć kotów), do zbioru walidacyjnego trafiło 1000 próbek (500 zdjęć psów i 500 zdjęć kotów), zaś do zbioru testowego ostatnie 1000 próbek (500 zdjęć psów i 500 zdjęć kotów). W celu dopasowania rozmiaru obrazów do rozmiaru wejścia sieci neuronowych wszystkie obrazy ze zbioru treningowego i walidacyjnego zostały przeskalowane do rozmiaru 150x150 pikseli. Następnie przeskalowane zostały wartości pikseli, tak aby zawierały się w przedziale od 0 do 1.

6. Stworzenie modelu konwolucyjnej sieci neuronowej do klasyfikacji obrazów graficznych

Celem budowy modelu wykorzystana została klasa Sequential biblioteki Keras. Model wykorzystywał następujące warstwy: Conv2D, MaxPooling2D, Flatten oraz Dense.

7. Przeprowadzenie badań wydajnościowych modelu

Zbadana została jakość wytrenowanego modelu poprzez określenie dokładności trenowania i walidacji oraz straty trenowania i walidacji. Wynik

tego badania został potraktowany jako benchmark do kolejnych modeli.

8. *Przeprowadzenie argumentacji danych*

Zastosowane zostały następujące modyfikacje: odbicie w pionie oraz w poziomie, obroty, rozciąganie i zwężanie oraz przesunięcia. Losowa modyfikacja była stosowana przed każdym podaniem zdjęcia na sieć w celu wygenerowania nowych danych wejściowych.

9. *Przeprowadzenie badań wydajnościowych modelu z wykorzystaniem argumentacji danych*

Przeprowadzone zostały badania jakości wytrenowanego modelu poprzez określenie dokładności trenowania i walidacji oraz straty trenowania i walidacji.

10. *Zastosowanie transfer learningu do procesu uczenia*

Transfer learning polega na wykorzystaniu już przetrenowanego modelu i wykorzystaniu architektury takiego modelu, jak i wag w innym procesie uczenia. W tym celu zastosowana została architektura modelu VGG16 (zawierającego 16 warstw) przetrenowanego na zbiorze Imagenet. Zbiór Imagenet składa się z 1,4 mln obrazów podzielonych na 1000 klas, które zawierają także różne rasy psów i kotów.

11. *Przeprowadzenie badań wydajnościowych modelu z wykorzystaniem argumentacji danych i transfer learningu*

Zbadana została jakość wytrenowanego modelu poprzez określenie dokładności trenowania i walidacji oraz straty trenowania i walidacji.

12. *Analiza porównawcza uzyskanych wyników*

Porównane zostały wszystkie uzyskane wyniki badań utworzonych modeli z zastosowaniem analizy statystycznej (dokładność, czułość, swoistość).


13. *Prezentacja wyników eksperymentu*

Wszystkie wyniki zostały opublikowane w dokumentacji projektowej.

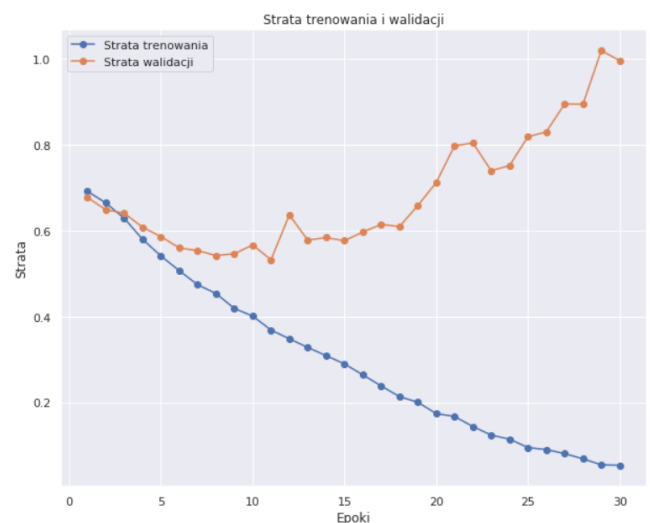
9. BADANIA

Pierwszy etap

W trakcie pierwszego etapu badań, została stworzona sama sieć konwolucyjna bez zastosowania transfer learningu oraz metod dostrajania. Wynik tego badania posłuży jako benchmark dla kolejnych modeli.



Rysunek 1. Dokładność trenowania i walidacji – etap pierwszy




Rysunek 2. Strata trenowania i walidacji – etap pierwszy

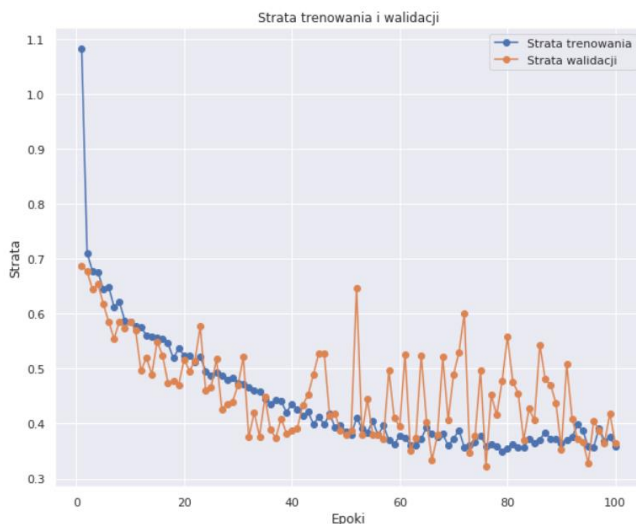
Wykresy przedstawiają, że model uległ przetrenowaniu już po 11 epokach, uzyskując dokładność na poziomie około 73%. Nie jest to jednak zadowalający wynik.

Drugi etap

Podczas drugiego etapu na model z poprzedniego etapu została zastosowana argumentacja danych.



Rysunek 3. Dokładność trenowania i walidacji – etap drugi

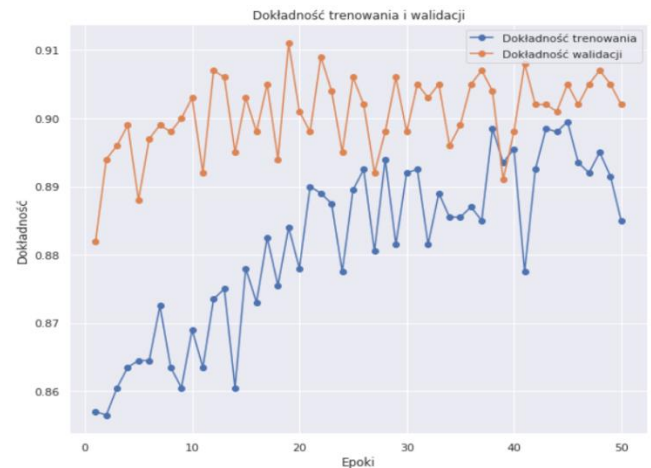


Rysunek 4. Strata trenowania i walidacji – etap drugi

Po zastosowaniu techniki argumentacji danych model znacząco poprawił swoją wydajność. Dokładność modelu oscyluje w granicach 85%. Z funkcji straty wynika, że sam model ulega przeuczeniu po około 40 epokach. Niestabilność miary dokładności na danych walidacyjnych jest duża.

Trzeci etap

W czasie trzeciego etapu do modelu został dodany transfer learning.



Rysunek 5. Dokładność trenowania i walidacji – etap trzeci




Rysunek 6. Strata trenowania i walidacji – etap trzeci

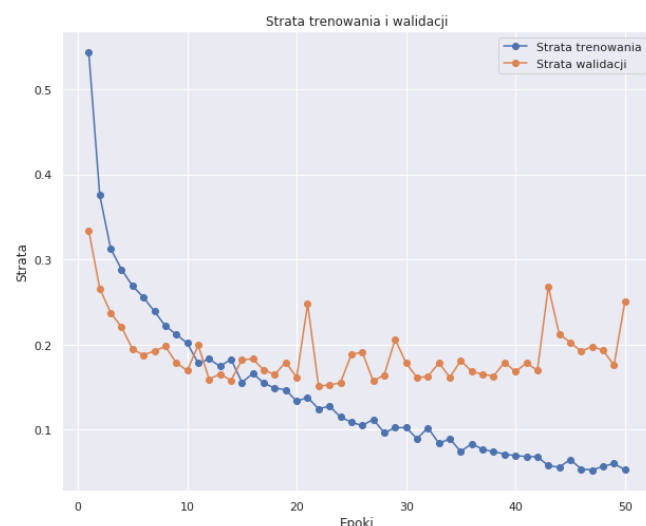
Model osiąga dokładność na poziomie 90%, więc nastąpiła poprawa w stosunku do modelu bez zastosowanego transfer learningu. Przeuczenie następuje po około 15-18 epokach. Stabilność dokładności na zbiorze walidacyjnym uległo znaczącej poprawie. Zastosowanie transfer learningu pozwoliło ograniczyć problem nadmiernego szumu.

Czwarty etap

Ostatni etap polegał na dostrojeniu transfer learningu.



Rysunek 7. Dokładność trenowania i walidacji – etap czwarty



Rysunek 8. Strata trenowania i walidacji – etap czwarty

Model po zastosowaniu dostrajania osiąga dokładność na poziomie 94%. Uzyskany wynik oznacza znaczną poprawę w stosunku do modelu pierwotnego (około 73%). Trenowanie można było zakończyć po 8-9 epokach, ponieważ model później ulega przeuczeniu.

Przeprowadzono analizę jakościową badanych systemów w celu lepszego poznania działania oraz zachowania się algorytmów głębokiego uczenia. Przeanalizowano zdjęcia błędnie sklasyfikowane przez sieć neuronową. W wyniku zbadania swoistości oraz czułości można zauważyć, że stosunek zbioru obrazów błędnie sklasyfikowanych do wszystkich obrazów jest zbliżony zarówno dla danych przedstawiających koty ('0') oraz psy ('1'). Wyniki eksperymentu przedstawione zostały w tabeli *Tabela 1*.

Tabela 1. Wyniki klasyfikacji

	precision	recall	f1-score	support
0	0.97	0.91	0.94	500
1	0.91	0.97	0.94	500
accuracy			0.94	1000
macro avg	0.94	0.94	0.94	1000
weighted avg	0.94	0.94	0.94	1000

10. PODSUMOWANIE

Konwolucyjne sieci neuronowe są bardzo dobrymi modelami uczenia maszynowego w zadaniach związanych z przetwarzaniem obrazów. Sieci konwolucyjne można trenować nawet na małych zbiorach danych, w tym celu pomocna okazuje się argumentacja danych i transfer learning. Sieci te, potrzebują jednak wydajnych jednostek obliczeniowych GPU. Możliwość stosowania transfer learningu pozwala trenować modele w znacznie krótszym czasie przy zdecydowanie większej skuteczności wobec modelu opartego tylko na nieprzetrenowanych danych. Techniki dostrajania pozwalają przystosować wyuczone wcześniej modele do określonego problemu. Powinno to prowadzić do poprawy skuteczności pracy modelu. Analiza jakościowa działania sieci neuronowej umożliwia przeanalizowanie sposobu wnioskowania sieci neuronowej. Dalsze badania w kierunku zrozumienia sposobu wnioskowania głębokich sieci neuronowych pozwolą na budowanie algorytmów budzących zaufanie, co jest istotne w zastosowaniach medycznych oraz finansowych. Kolejnym wyzwaniem jest stworzenie algorytmów wydajnych obliczeniowo, co umożliwi stosowanie algorytmów w znacznie większej liczbie urządzeń, które nie są wyposażone w wydajne jednostki obliczeniowe. W tym celu istotnym będzie opracowanie algorytmów automatycznego doboru struktur optymalnych pod względem wydajności np. ilość zużywanej pamięci czy ilość wykonywanych operacji matematycznych.

11. BIBLIOGRAFIA

- 1) Alex Krizhevsky, Ilya Sutskever, and Hinton Geoffrey E., "ImageNet Classification with Deep Convolutional Neural Networks," Advances in Neural Information Processing Systems 25, 2012.
- 2) Yann LeCun, Yoshua Bengio, and Geoffrey Hinton, "Deep learning", Nature, vol. 521, no. 7553, p. 436, 2015.
- 3) Le Kang, Jayant Kumar, Peng Ye, Yi Li, David Doermann „Convolutional Neural Networks for Document Image Classification”, 2014
- 4) Alexander Gomez, German Diez, Augusto Salazar, Angelica Diaz „Animal Identification in Low Quality Camera – Trap Images Using Very Deep Convolutional Neural Networks and Confidence Thresholds”, 2016
- 5) Ling Shao, Fan Zhu, Xuelong Li „Transfer Learning for Visual Categorization: A Survey”, 2014

- 6) https://ml-repository-krakers.s3-eu-west-1.amazonaws.com/kaggle+/cats_and_dogs/dogs-vs-cats.zip
- 7) Francois Chollet, „Deep Learning Praca z językiem Python i biblioteką Keras”, Helion, Gliwice, 2019